

인공지능을 활용한 양극소재 기반 배터리 특성 예측

02 AI 적용을 위한 피처 엔지니어링

목차


—
AI 적용을 위한 피쳐
엔지니어링

- 01 데이터셋이 내포하기 쉬운 문제점들
- 02 정규화 및 표준화
- 03 상관관계 분석
- 04 불필요한 구성 요소 제거
- 05 도메인 지식이란
- 06 피쳐 엔지니어링 기법

01

데이터셋이 내포하기 쉬운 문제점들

④ 인공지능 모델 학습 과정



☑ 데이터셋이란?



- 학습하려는 인공지능 모델에 핵심적인 데이터를 모아 놓은 것
- 컴퓨터가 이해할 수 있는 형태의 정보로 변환
 - 숫자 데이터
 - 이미지 & 비디오
 - 텍스트
 - 사운드
- 일반적으로 정답 데이터(라벨)을 포함하고 있음
- 데이터셋의 양과 질이 인공지능 모델의 성능을 크게 좌우함


④ 불완전한 데이터셋



- 필요한 데이터 항목이 처음부터 누락된 경우
- 이를 부분적으로 관찰된(partially observed) 데이터라고 함
- 아무리 노력해도 성능을 올릴 수 없는 근본적인 원인이 됨
- 최악의 경우 데이터를 모두 폐기하고 다시 수집해야 할 수도 있음

해결하고자 하는 문제를 정확하게 정의하고,
데이터 수집 계획을 면밀하게 수립해야 함

❑ 불완전한 데이터셋 예시




숙박 시설 가격 예측 문제



필수적으로 관찰되어야 할 데이터 항목:
요일, 공휴일, 특수상황(축제, 대회, 운동경기) 등

④ 불균형한 데이터셋



- 라벨 당 데이터 크기 사이에 큰 불균형이 존재하는 경우
- 인공지능 모델 특성상 적은 데이터 예측을 포기하고 다수의 데이터만 잘 맞추려는 경향을 보임 (실제 전체 성능은 향상됨)
- 데이터 불균형은 간단한 방법들로 문제를 일부 완화할 수 있음

데이터 수집 시 균형적으로 데이터를 획득하려고 노력해야 함

④ 불균형한 데이터셋 예시




다양한 사물이 포함된 이미지 데이터셋
(강아지, 머핀 등이 포함되지만, 데이터가 불균형함)



학습 데이터에 강아지 사진이 훨씬 많았다면
대부분 애매한 사진에서 강아지라고 예측함

④ 이상치 데이터



- 수집한 데이터 중 예외로 처리해도 무방한 데이터를 뜻함
- 적은 수의 이상치는 성능에 큰 영향을 끼치지 않지만, 확실한 이상치라면 통일성을 위해 제거하는 것이 좋음
- 이상치는 여러가지 불확실성에 의해 생김
 - 사람의 실수
 - 센서의 한계
 - 데이터 유지 보수 오류
 - 자연적인 예외 상황


이상치는 자연적으로 생기는 결함이므로, 데이터 수집 후 제거해주는 것이 이상적임

④ 이상치 데이터 판단 기준

Detecting Outliers with z-Scores

28

An **outlier** is an extremely large or extremely small data value relative to the rest of the data set. It may represent a data entry error, or it may be genuine data.



Z-Score 기반의 이상치(outlier) 판단

- 데이터가 가우스 분포에 따른다고 가정함
- 이때 관측치들의 평균과 표준편차를 이용하면 Z-Score를 구할 수 있음
- 이를 이용해 관측치들의 일반적 통계량에서 크게 벗어나는 데이터를 이상치로 판단함

02

정규화 및 표준화

④ 각양각색의 빅데이터

[ET시론]국가 R&D 미래, '연구데이터'

수년간 정부 연구개발(R&D) 투자는 신기록을 경신 중이다. 올해 국가 R&D 예산도 29조8000억원의 역대 최대 규모로 편성됐다. 우리가 살길은 과학기술뿐이라는 국민의 믿음 덕분이다. 코로나 사태로 힘들어도 다음 해 심을 씨앗에 결코 손을 대지 않는다는 농부의 지혜와 인내를 떠올리게 한다. 세계는 이전과 비교할 수 없을 정도의 큰 변화를 겪었다. 4차 산업혁명이 도래한 이후 과학기술은 물론 사회경제 전 분야가 인공지능(AI)과 빅데이터 기반으로 빠르게 바뀌고 있다. 디지털 전환 역시 급속도로 진행되고 있다.


(중략)

해외 글로벌 연구데이터플랫폼과의 협력 및 데이터 연계를 적극적으로 추진해 유럽의 OpenAIRE, 호주의 ARDC, 일본의 IRDB 등 세계 최고 연구데이터 플랫폼들과 연계하고 있다.

분야별 연구데이터 수집을 위해 대형 연구장비 분야 연구데이터(GSDC), AI 및 인공지능 분야 연구데이터(AIHub)와도 연계돼 있다. 이 같은 노력을 통해 데이터온은 작년 말 기준 **9개 기관 3만3000여 데이터셋**의 국내 데이터와 유럽·호주·일본 등 약 **113만 데이터셋** 해외 데이터를 연계해 연구자들이 필요로 하는 국내외 연구데이터를 제공하고 있다.




④ 정규화(Normalization)




- 데이터를 일정한 범위 내로 조정하는 방법
- 가장 흔한 방법은 0부터 1사이의 값으로 재조정하는 것
- 이상치가 제거된 후, 최솟값과 최댓값을 이용해 정규화를 진행함

④ 정규화 과정




1. 가장 먼저 이상치를 식별한 뒤 제거한다.
2. 모든 데이터에 최솟값을 빼준다.
3. 데이터의 범위로 나눠준다. 이때, 데이터의 범위는 (최댓값 - 최솟값)이다.
4. 0부터 1 사이로 정규화된 데이터를 저장한다.

④ 표준화(Standardization)




- 데이터의 평균을 0으로, 표준편차를 1로 조정하는 방법
- 데이터가 정규분포를 따를 때 특히 유용함
- 자연에 존재하는 대부분의 데이터는 정규분포를 따르기 때문에 일반적으로 적용하는 방법임
- 많은 머신러닝 알고리즘이 입력데이터가 정규분포임을 가정하고 있어서, **표준화를 하지 않으면 외부 알고리즘을 사용할 때 문제가 될 수 있음**

☑ 정규분포를 따르는 데이터 예시




자연적으로 존재하는 통계량 분포는 대부분 정규분포를 따르고, 이는 수학적으로도 증명할 수 있음.

대표 예시 (1): 신장 데이터



대표 예시 (2): 수능 점수

④ 표준화 과정




1. 정규화된 데이터를 불러온다..
2. 모든 데이터에 평균값을 빼준다.
3. 데이터의 표준편차로 나뉜다.
4. 평균은 0, 표준편차는 1의 정규분포를 따르는 표준화된 데이터를 저장한다.

03


상관관계 분석

☑ 상관관계의 중요성




- 변수간의 선형적 관계를 나타냄
- 데이터 사이의 연관성을 직관적으로 이해할 수 있음
- 피처 엔지니어링을 진행하기 위한 가장 기초적인 분석

④ 상관관계 계수 계산




피어슨 상관 계수(Pearson Correlation Coefficient)



상관관계 계수에 따른 데이터 분포 예시

✔ 히트맵 시각화



- 상관관계 분석 결과를 히트맵(Heat Map)형태로 나타냄
- 자기 자신과의 상관관계는 1로 나타남
- 상관계수의 크기가 클수록 진한 색으로 표현함
- 히트맵을 통해 예측하고자 하는 변수와 상관된 변수를 곧바로 확인할 수 있는 경우도 있음

☑ 히트맵 예시

	Materials Id	Formula	Spacegroup	Formation Energy (eV)	E Above Hull (eV)	Band Gap (eV)	Nsites	Density (gm/cc)	Volume	Has Bandstructure	Crystal System
Materials Id	1.000000	0.332940	0.164018	-0.014277	0.012059	0.116107	0.088465	0.045163	0.083649	-0.008116	-0.022733
Formula	0.332940	1.000000	0.037486	-0.189702	0.080453	0.078005	0.195797	-0.018926	0.173728	-0.063230	0.156222
Spacegroup	0.164018	0.037486	1.000000	-0.069654	0.008746	0.048523	0.180906	0.038247	0.167167	0.025617	-0.104080
Formation Energy (eV)	-0.014277	-0.189702	-0.069654	1.000000	0.272422	-0.438429	-0.270777	0.485055	-0.305389	0.198019	-0.009504
E Above Hull (eV)	0.012059	0.080453	0.008746	0.272422	1.000000	-0.468094	0.068422	-0.022966	0.097230	-0.087987	0.066552
Band Gap (eV)	0.116107	0.078005	0.048523	-0.438429	-0.468094	1.000000	0.104626	-0.348753	0.152620	0.021514	-0.147028
Nsites	0.088465	0.195797	0.180906	-0.270777	0.068422	0.104626	1.000000	-0.178178	0.980329	-0.550676	-0.000647
Density (gm/cc)	0.045163	-0.018926	0.038247	0.485055	-0.022966	-0.348753	-0.178178	1.000000	-0.293185	0.188391	0.124988
Volume	0.083649	0.173728	0.167167	-0.305389	0.097230	0.152620	0.980329	-0.293185	1.000000	-0.566325	-0.012862
Has Bandstructure	-0.008116	-0.063230	0.025617	0.198019	-0.087987	0.021514	-0.550676	0.188391	-0.566325	1.000000	0.021126
Crystal System	-0.022733	0.156222	-0.104080	-0.009504	0.066552	-0.147028	-0.000647	0.124988	-0.012862	0.021126	1.000000

양극재 결정구조 분류 데이터셋의 상관관계 히트맵


- 위 결과를 통해:
- 1) Volume과 Nsites는 상관관계가 큰 데이터,
 - 2) Crystal System과 큰 상관관계가 있는 데이터가 없음

등을 유추할 수 있음

04

불필요한 구성 요소 제거

☑ 인공지능의 과적합 문제



- 인공지능 모델은 주어진 학습 데이터에서 일반적인 패턴을 찾도록 학습됨
- 따라서, 학습 데이터가 예측하고자 하는 정답 데이터에 연관이 있다고 암묵적으로 동의하는 것
- 불필요한 데이터 항목에서 우연히 패턴을 찾을 과적합 문제를 야기할 수 있음

④ 상관관계 분석에 따른 불필요한 구성 요소 식별 - 사례 (1)

	Materials Id	Formula	Spacegroup	Formation Energy (eV)	E Above Hull (eV)	Band Gap (eV)	Nsites	Density (gm/cc)	Volume	Has Bandstructure	Crystal System
Materials Id	1.000000	0.588513	0.897105	0.168878	0.205312	-0.178904	-0.011202	0.130430	-0.013843	0.038055	0.927930
Formula	0.588513	1.000000	0.477374	0.285640	0.223831	-0.232847	0.074695	0.092797	0.082929	-0.072575	0.456263
Spacegroup	0.897105	0.477374	1.000000	0.023937	0.142385	-0.163022	-0.012620	0.119096	-0.017846	0.037261	0.945752
Formation Energy (eV)	0.168878	0.285640	0.023937	1.000000	0.272422	-0.438429	-0.270777	0.485055	-0.305389	0.198019	-0.009504
E Above Hull (eV)	0.205312	0.223831	0.142385	0.272422	1.000000	-0.468094	0.068422	-0.022966	0.097230	-0.087987	0.066552
Band Gap (eV)	-0.178904	-0.232847	-0.163022	-0.438429	-0.468094	1.000000	0.104626	-0.348753	0.152620	0.021514	-0.147028
Nsites	-0.011202	0.074695	-0.012620	-0.270777	0.068422	0.104626	1.000000	-0.178178	0.980329	-0.550676	-0.000647
Density (gm/cc)	0.130430	0.092797	0.119096	0.485055	-0.022966	-0.348753	-0.178178	1.000000	-0.293185	0.188391	0.124988
Volume	-0.013843	0.082929	-0.017846	-0.305389	0.097230	0.152620	0.980329	-0.293185	1.000000	-0.566325	-0.012862
Has Bandstructure	0.038055	-0.072575	0.037261	0.198019	-0.087987	0.021514	-0.550676	0.188391	-0.566325	1.000000	0.021126
Crystal System	0.927930	0.456263	0.945752	-0.009504	0.066552	-0.147028	-0.000647	0.124988	-0.012862	0.021126	1.000000

만약 예측하고자 하는 데이터에 강한 상관관계를 갖는 데이터 항목이 존재한다면,

해당 데이터들의 **선형적인 조합**으로 높은 정확도의 예측이 가능할 수도 있음

그 외의 데이터들을 불필요한 구성 요소로 식별

☑ 상관계수 분석에 따른 불필요한 구성 요소 식별 - 사례 (2)

	Materials Id	Formula	Spacegroup	Formation Energy (eV)	E Above Hull (eV)	Band Gap (eV)	Nsites	Density (gm/cc)	Volume	Has Bandstructure	Crystal System
Materials Id	1.000000	0.332940	0.164018	-0.014277	0.012059	0.116107	0.088465	0.045163	0.083649	-0.008116	-0.022733
Formula	0.332940	1.000000	0.037486	-0.189702	0.080453	0.078005	0.195797	-0.018926	0.173728	-0.063230	0.156222
Spacegroup	0.164018	0.037486	1.000000	-0.069654	0.008746	0.048523	0.180906	0.038247	0.167167	0.025617	-0.104080
Formation Energy (eV)	-0.014277	-0.189702	-0.069654	1.000000	0.272422	-0.438429	-0.270777	0.485055	-0.305389	0.198019	-0.009504
E Above Hull (eV)	0.012059	0.080453	0.008746	0.272422	1.000000	-0.468094	0.068422	-0.022966	0.097230	-0.087987	0.066552
Band Gap (eV)	0.116107	0.078005	0.048523	-0.438429	-0.468094	1.000000	0.104626	-0.348753	0.152620	0.021514	-0.147028
Nsites	0.088465	0.195797	0.180906	-0.270777	0.068422	0.104626	1.000000	-0.178178	0.980329	-0.550676	-0.000647
Density (gm/cc)	0.045163	-0.018926	0.038247	0.485055	-0.022966	-0.348753	-0.178178	1.000000	-0.293185	0.188391	0.124988
Volume	0.083649	0.173728	0.167167	-0.305389	0.097230	0.152620	0.980329	-0.293185	1.000000	-0.566325	-0.012862
Has Bandstructure	-0.008116	-0.063230	0.025617	0.198019	-0.087987	0.021514	-0.550676	0.188391	-0.566325	1.000000	0.021126
Crystal System	-0.022733	0.156222	-0.104080	-0.009504	0.066552	-0.147028	-0.000647	0.124988	-0.012862	0.021126	1.000000

만약 예측하고자 하는 데이터에 강한 상관계수를 갖는 데이터 항목이 없다면,

나머지 데이터들과 **비선형적**인 관계를 갖고 있을 확률이 높음

상관계수가 큰 데이터 항목 식별 및 제거

05

도메인 지식이란

④ 도메인 지식과 인공지능

서울대 국문학과 박진호 교수, 언어인공지능이 언어학 도메인 지식과 만나면 AI 자연어처리 능력은 어떻게 변화될까?

Q: 현재의 이런 패러다임으로 가면 언어, 한국어를 전공하는 학생들, 연구자들의 미래 전망은 어떻습니까?

A: 자연어처리에서 언어학자가 기여할 수 있는 부분을 우리가 찾아서 후학들에게 길을 열어줘야겠죠. 그래서 제가 관심을 갖고 연구해 온 것은, 현재의 딥러닝 기반 AI나 자연어처리 시스템을 완전히 갈아엎자는 건 아니고 최대한 활용을 하되 언어학의 도메인 지식도 활용하여 최선의 결과를 얻자는 겁니다.

딥러닝을 갈아엎지 말자는 것은, 과거에 도메인 전문가가 규칙을 만들고 그걸 코드화하는 방식에 비해서 딥러닝이 패턴을 잘 포착하고 더 잘 하는 부분이 분명히 있기 때문입니다. 딥러닝이 더 잘 하는 부분은 더 잘 할 수 있게 하되, 그렇게 모델을 크게 키울 필요는 없고 최소한의 모델로 좋은 결과를 얻자는 겁니다. 딥러닝 기반 언어모델이 잘 못하는 부분들도 있는데 그런 틈새를 찾아서 언어학의 도메인 지식으로 메꿔줘서, 자연어처리 시스템의 성능 향상을 꾀하자는 겁니다.




④ 도메인 지식(Domain Knowledge)



- 특정 영역 또는 주제에 대한 전문적인 이해와 정보
- 사람이 경험, 교육, 훈련 등을 통해 쌓을 수 있는 지식
- 각 분야의 전문가들이 인공지능을 다룰 때 **사람의 지식**을 개입하는 경우가 많음
- 때로는 도메인 지식이 성능 향상의 핵심이 되기도 함

☑ 상관계수의 오류




- 높은 선형적 상관계수를 갖더라도 **인과성을 갖는 것은 아님**
- 아이스크림 판매량과 상어 피해의 상관계수가 높은 것은 인과성이 없는 우연의 결과임

데이터셋을 전문적인 지식을 통해 분석하고
전처리해야 함

☑ 도메인 지식 활용 예시

Only Elements																		At Least Elements										Formula										He	
Li		Be		28		Ni		*		Select elements to search for batteries with only these elements										B		C		N		O		F		Ne									
Na		Mg				Nickel														Al		Si		P		S		Cl		Ar									
K		Ca		Sc		Ti		V		Cr		Mn		Fe		Co		Ni		Cu		Zn		Ga		Ge		As		Se		Br		Kr					
Rb		Sr		Y		Zr		Nb		Mo		Tc		Ru		Rh		Pd		Ag		Cd		In		Sn		Sb		Te		I		Xe					
Cs		Ba		La-Lu		Hf		Ta		W		Re		Os		Ir		Pt		Au		Hg		Tl		Pb		Bi		Po		At		Rn					
Fr		Ra		Ac-Lr		Rf		Db		Sg		Bh		Hs		Mt		Ds		Rg		Cn		Nh		Fl		Mc		Lv		Ts		Og					
						La		Ce		Pr		Nd		Pm		Sm		Eu		Gd		Tb		Dy		Ho		Er		Tm		Yb		Lu					
						Ac		Th		Pa		U		Np		Pu		Am		Cm		Bk		Cf		Es		Fm		Md		No		Lr					



- 원소의 이름은 사람이 인위적으로 정해준 것임
- 원소의 특성을 예측할 때 이름은 학습 데이터로 제공할 필요가 없음

- pH와 수소이온 농도는 log 관계를 갖고 있음
- 두 데이터 중 하나는 삭제하는 것이 합당함

06

피처 엔지니어링 기법

④ 대표적인 피처 엔지니어링 기법들

연속형 데이터
전처리

범주형 데이터
전처리

불균형 데이터
샘플링

결측치 대체

④ 연속형 데이터 전처리




- 연속형 데이터, 또는 숫자 데이터라고 부름
- 일반적으로 많은 고유값을 가짐
- 정확한 숫자가 중요하지 않다면 이산화(구간화)하여 복잡성을 줄일 수 있음
- 구간을 설정할 때 도메인 지식을 잘 활용해야 함
- 모델의 과적합을 방지하는 효과가 있음
- Ex) 나이 데이터를 "10대", "20대" 등으로 이산화

④ 범주형 데이터 전처리



- 범주형 데이터, 또는 카테고리형 데이터라고 부름
- 일반적으로 **적은 고유값**을 가짐
- 대부분 순서가 없는 것이 특징임
- 전처리 방법에는 원-핫 인코딩과 순서 인코딩이 있음
- Ex) "홍길동", "서울" 등 문자열 형태인 경우가 많음

④ 원-핫 인코딩(One-Hot Encoding)




- 가장 일반적인 범주형 데이터 인코딩 방법
- 각 범주 하나 당 새로운 데이터 항목 하나를 생성
- 데이터 샘플이 해당 범주에 속한다면 1, 그렇지 않다면 모두 0을 갖게 됨
- 이러한 데이터 항목이 범주의 갯수만큼 생성됨
- 범주가 많을 경우 메모리 효율과 계산 효율이 떨어짐

☑ 순서 인코딩




- 범주형 데이터가 순서를 가질 때 사용하는 방법
- 문자열인 범주 정보를 숫자 순서로 변경
- 일대일 변환이므로 메모리 효율이 좋음
- 모든 범주형 데이터에 적용하기에는 적절하지 않음

✓ 결측치 대체(Data Imputation)



- 항목에 속하지 않아서 비어두거나, 측정 실패로 인해 결측된 데이터
- 여러가지 결측치 대체 방법이 있음
 - 평균값, 중앙값, 최빈값 대체: 결측치를 모두 대표값으로 대체하는 방법
 - 예측 모델 사용: 별도의 머신러닝을 통해 결측치 대체. 데이터 전처리량은 거리가 멀
 - 다중 대체: 통계적인 추정을 통해 불확실성을 고려한 데이터 대체

④ 불균형 데이터 샘플링



- 범주형 데이터를 예측하는 문제에서 사용함
- 범주 간 데이터 불균형이 있을 때 **샘플링**을 통해 데이터 수를 조절하는 방법
- 오버 샘플링: 적은 데이터를 더 자주 뽑아서 비율을 맞추는 방법
- 언더 샘플링: 많은 데이터를 덜 뽑아서 비율을 맞추는 방법