

인공지능을 활용한 양극소재 기반 배터리 특성 예측

03 양극재 결정구조 분류 머신러닝 모델의 이해와 적용 (1)

목차


—
양극재 결정구조 분류
머신러닝 모델의 이해와
적용 (1)

- 01 선형 회귀란
- 02 선형 회귀의 원리
- 03 선형 회귀 모델 학습
- 04 다중 선형 회귀
- 05 성능 평가 지표
- 06 로지스틱 회귀 모델

01

선형 회귀란

☑ 대표적인 인공지능 모델




용어

의사결정트리: 분류와 회귀 문제에 모두 사용되는 비선형 모델

서포트 벡터 머신(SVM): 데이터를 높은 차원으로 매핑하여 복잡한 패턴을 찾아내는 모델


인공신경망(ANN): 생물학적 신경망에서 영감을 받은 복잡한 인공지능 모델

☑ 선형 회귀란?






- 선형 회귀: 독립변수와 종속변수 간의 **선형** 관계를 모델링하는 통계 기법
- 독립변수: 흔히 X 로 표기하며, 예측하려는 결과에 영향을 준다고 가정하는 입력값
- 종속변수: 흔히 y 로 표기하며, 예측하려는 결과 혹은 출력값

☑ 선형 회귀의 가정들 - (1) 선형성




- 독립변수와 종속변수 사이에는 선형 관계가 있다는 가정
- 독립변수의 **선형 조합**으로 종속변수를 구성할 수 있음
$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 \dots + \beta_n X_n$$
- 일반적으로 하나의 독립변수와 하나의 종속변수를 그래프 시각화했을 때, 직선으로 표현이 가능함
- 비선형성을 적용한 독립변수가 있다면 비선형성을 표현할 수 있음
 - Ex) 제곱을 적용한 독립변수의 선형 조합으로 2차 함수를 표현

☑ 선형 회귀의 가정들 - (2) 정규성



- 데이터가 정규분포를 따르고 있다는 가정
- 특히, 회귀 분석에서는 잔차의 분포에 대한 정규성을 가정함
- 잔차: 모델에 의해 예측된 값과 실제 값 사이의 차이

☑ 선형 회귀의 가정들 - (3) 등분산성



- 독립변수들의 분산이 동일하다는 가정
- 회귀 분석에서는 예측된 값의 오차의 분산이 일정하다고 가정함
- 등분산성이 위배되면 이차성(Heteroscedasticity)라고 부르며, 이때 회귀 모델 결과의 신뢰성이 저하됨

☑ 선형 회귀의 가정들 - (4) 독립성

X1	1	-0.011	-0.055	-0.019	0.51
X2	-0.011	1	0.022	0.036	0.38
X3	-0.055	0.022	1	0.019	0.75
X4	-0.019	0.036	0.019	1	0.017
y	0.51	0.38	0.75	0.017	1
	X1	X2	X3	X4	y

- 독립변수들이 서로 독립이라는 가정
- 독립변수가 다른 독립변수에 영향을 주지 않아야 함
- 이는 상관관계 분석을 통해 확인할 수 있음
- 피처 엔지니어링을 통해 상관관계가 큰 데이터를 제거해줘야 함

02

선형 회귀의 원리

④ 선형 회귀의 목적




- 독립변수 X 와 종속변수 Y 사이의 관계를 가장 잘 설명하는 직선을 찾는 것이 목적

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 \dots + \beta_N X_N$$

- β_0 는 Y 축 절편, β_n 은 X_N 독립변수의 기울기(회귀 계수)를 의미함
- 단변수 회귀 문제의 경우 간단한 1차 함수 형태를 띠م



$$Y = \beta_0 + \beta_1 X_1$$

④ 단변수 선형 회귀 모델




- 보라색 데이터 샘플은 실제 데이터를 의미
- 빨간색 직선은 회귀 모델이 학습한 회귀 계수를 이용해 그린 1차 방정식

☑ 잔차(Residuals)



- 학습된 회귀 모델의 예측값과 실제값 사이의 차이를 오차(Error), 혹은 잔차(Residuals)라고 함
- 잔차를 최소화하는 방향으로 학습이 진행됨
- 즉, 최소의 잔차를 갖는 회귀 계수 β_0, β_1 를 찾는 것이 목표

④ 제공 오차의 합(Sum of Squared Error)



- 모든 잔차를 제공한 총합을 제공 오차의 합(SSE)이라고 함
- 회귀 모델의 예측값을 $\tilde{y}$ 라고 할 때, 잔차를 아래와 같이 정의함

$$\text{Error} = y_i - \tilde{y}_i$$

- SSE는 아래와 같이 정의함


$$\text{SSE} = \sum_{i=1}^N (y_i - \tilde{y}_i)^2$$

- SSE의 기울기를 구하면 오차가 작아지는 방향을 나타내게 됨

03

선형 회귀 모델 학습


☑ 손실함수(Loss Function)



- 잔차를 기반으로 모델의 성능을 평가함
- 잔차로 성능을 어떻게 수치화하는지를 손실함수라고 함
- 가장 흔한 손실함수로는 MSE(Mean Squared Error)가 있음
- MSE는 잔차를 제공한 후 평균을 내는 방법, 즉 SSE의 평균값

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (y_i - \tilde{y}_i)^2$$

☑ 볼록(Convex) 함수




- 볼록 함수의 정의는 아래와 같음

$$f(tx + (1 - t)y) \leq t(fx) + (1 - t)f(y)$$


- 함수 내의 어떤 두 점을 선택하더라도, 두 점을 잇는 선분이 함수의 그래프 위에 놓이는 성질
- 볼록 함수의 특징은 국소 최솟값이 전역 최솟값과 같음
- MSE는 전형적인 볼록 함수 형태임
- 함수 최솟값에서 오차가 가장 작아짐

기울기 계산




- 볼록 함수에서 국소 최솟값의 미분값은 0임
- 경사 하강법(Gradient Descent) 등의 방법을 이용해 최적화를 진행할 수 있음
- 선형 회귀 문제에서는 MSE가 국소 최솟값을 갖도록 하는 회귀 계수를 해석적으로 계산할 수 있음
- 이러한 방법을 최소제곱법이라고 함

④ 선형 회귀 모델 학습 과정




회귀 모델 사용




- 선형 회귀 모델의 학습이 끝나면 회귀 계수들을 얻게 됨
- 회귀 계수 β_0, β_1 를 이용해 새로운 데이터에 대해 예측을 수행할 수 있음
- 예측 단계에서는 **고정된 회귀 계수**를 사용하고 추가적인 학습을 진행하지 않음
- 선형 예측 모델이기 때문에 표현력이 떨어진다는 단점이 있음

☑ 단변수 회귀 모델 예측 결과 예시



학습 데이터를 이용해 학습된
선형 회귀 모델의 예측 결과 그래프



테스트 데이터에 대한
선형 회귀 모델의 예측 결과 그래프

04

다중 선형 회귀

④ 선형 회귀 문제 분류

단변수 선형 회귀

독립변수 1개 &
종속변수 1개

다변수 선형 회귀

독립변수 N개 &
종속변수 1개

다변수 다중 출력 선형 회귀

독립변수 N개 &
종속변수 M개





용어

독립변수: 흔히 X로 표기하며, 예측하려는 결과에 영향을 준다고 가정하는 입력값




종속변수: 흔히 y로 표기하며, 예측하려는 결과 혹은 출력값

☑ 다변수 선형 회귀 문제



- 2개 이상의 독립변수가 하나의 종속변수에 영향을 미칠 때의 선형 회귀 문제
- 단변수 선형 회귀 문제는 회귀 계수 β_0, β_1 를 찾는 것이 목표였다면,
다변수 선형 회귀 문제에서는 회귀 계수 $\beta_0, \beta_1, \beta_2, \dots, \beta_N$ 를 찾는 것이 목표

☑ 다변수 선형 회귀 모델 예측 결과



- 학습된 회귀 계수를 이용해 예측식을 구성할 수 있음

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 \dots + \beta_n X_n$$

- 예측식을 기반으로 테스트 데이터에 대한 예측을 수행함
- 파란색 데이터가 테스트 데이터, 빨간색 데이터가 예측 결과임

☑ 다변수 다중 출력 선형 회귀 문제

X1	1	-0.0025	-0.001	0.8	0.53
X2	-0.0025	1	0.027	0.54	0.29
X3	-0.001	0.027	1	0.27	0.8
y1	0.8	0.54	0.27	1	0.79
y2	0.53	0.29	0.8	0.79	1
	X1	X2	X3	y1	y2

- 2개 이상의 독립변수가 2개 이상의 종속변수에 영향을 미칠 때의 선형 회귀 문제







$$Y_1 = \beta_{10} + \beta_{11}X_1 + \beta_{12}X_2 \dots + \beta_{1n}X_n$$

...

$$Y_m = \beta_{m0} + \beta_{m1}X_1 + \beta_{m2}X_2 \dots + \beta_{mn}X_n$$

- $n \times m$ 개의 회귀 계수를 찾는 것이 목표

④ 다변수 다중 출력 선형 회귀 모델 예측 결과



05

성능 평가 지표


④ 성능 평가 지표(Evaluation Metrics)



- 머신 러닝 모델이 얼마나 데이터를 잘 예측하는지 측정하는 지표
- 모델 학습 시 사용한 비용 함수와 유사함
- 테스트 데이터에 대해서 측정한 평가 지표를 개선하는 것이 중요함
- 최소 제곱법의 비용 함수인 MSE 또한 성능 평가 지표로 사용될 수 있음

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (y_i - \tilde{y}_i)^2$$

☑ MSE(Mean Squared Error)




- 테스트 데이터의 오차를 모두 제곱한 뒤의 총합을 MSE라고 함

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (y_i - \tilde{y}_i)^2$$

- 큰 오차에 대해 큰 가중치를 부과하기 때문에 이상치에 민감한 것이 특징

☑ MAE(Mean Absolute Error)




- 테스트 데이터에 절댓값을 취한 뒤의 총합을 MAE라고 함

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |y_i - \tilde{y}_i|$$

- 모든 오차가 동일한 가중치를 가짐
- 이상치에 둔감, 혹은 강건한 것이 특징

☑ RMSE(Root Mean Squared Error)



- MSE의 제곱근을 RMSE라고 함

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \tilde{y}_i)^2}$$

- MAE와 유사하지만 큰 오차에 더 큰 가중치를 가짐
- 제곱근의 영향으로 MSE보다 이상치에 덜 민감함
- RMSE는 기존 종속변수의 단위를 가짐


④ R^2 결정 계수(Coefficient of Determination, R Square)

- 결정 계수는 회귀 모델의 설명력을 나타냄
- 0부터 1 사이의 값을 가짐
- $\bar{y}$ 는 데이터의 평균
- SST(Total Sum of Squares)는 종속변수의 전체 변동
- SSE(Explained Sum of Squares)는 모델에 의해 설명되지 않는 변동

$$R^2 = 1 - \frac{SSE}{SST} = 1 - \frac{\sum_{i=1}^N (\bar{y}_i - \tilde{y}_i)^2}{\sum_{i=1}^N (\bar{y}_i - y_i)^2}$$


- 즉, 모델이 종속변수의 **변동을 얼마나 설명할 수 있는가**를 나타냄

④ 결정 계수 예시



종속변수에 표준편차 1의 노이즈가 추가되었을 때

결정 계수 = 0.97



종속변수에 표준편차 10의 노이즈가 추가되었을 때

결정 계수 = 0.24

성능 평가 지표 정리

MSE (Mean Squared Error)	오차를 제곱하기 때문에 큰 오차에 대해 큰 가중치를 부과하고, 이상치에 민감한 것이 특징
MAE (Mean Absolute Error)	- 모든 오차가 동일한 가중치를 가지기 때문에 이상치에 둔감한 것이 특징 - 종속 변수의 단위를 갖는 지표
RMSE (Root Mean Squared Error)	- MAE와 유사하게 종속변수의 단위를 가지는 평가 지표 - 제곱근의 영향으로 MSE보다 이상치에 덜 민감함 - MAE와 비교했을 때 큰 오차에 더 큰 가중치를 가짐
R^2 (R Square)	- 모델이 데이터의 변동성을 얼마나 설명하고 있는지를 측정하는 지표 1에 가까울수록 데이터의 변동성을 완벽하게 설명하고 있음을 의미함

06


로지스틱 회귀 모델

④ 범주형 데이터 예측



- 범주형 데이터, 또는 카테고리형 데이터를 예측하는 회귀 문제
- 입력 변수의 단순한 선형 조합으로 데이터를 분류할 수는 없음
- 로지스틱 회귀 모델은 **로지스틱 함수**를 이용해 범주형 예측을 가능하게 함

④ 시그모이드(Sigmoid) 함수




- 실수를 입력받아 0과 1사이의 출력값을 반환하는 함수
- 입력 변수 0을 주변으로 **비선형적**인 값을 갖는 것이 특징

$$f(x) = \frac{1}{1 + e^{-x}}$$


- 특정값을 기준으로 삼으면 **이진 분류**가 가능함

④ 로지스틱 회귀 모델 학습 과정

충분한 검증 성능이 나올 때 까지 학습



㉟ 다중 분류 모델



- 로지스틱 회귀 모델의 이진 분류 특성을 이용해 다중 분류를 구현할 수 있음
- 이진 분류 모델을 트리(Tree) 형태로 구성해 다중 분류 모델 생성
- 로지스틱 모델은 선형 결정 경계를 가지므로, 복잡한 패턴을 가진 데이터에 **제한적인 성능**을 가짐