

인공지능을 활용한 양극소재 기반 배터리 특성 예측

04 양극재 결정구조 분류 머신러닝 모델의 이해와 적용 (2)

목차


—
양극재 결정구조 분류
머신러닝 모델의 이해와
적용 (2)

- 01 주성분 분석(PCA)
- 02 K-최근접 이웃(KNN)
- 03 결정 트리
- 04 랜덤 포레스트
- 05 XGBoost
- 06 분류 모델 성능 평가 지표


01

주성분 분석(PCA)


☑ 주성분 분석이란?



(a) CartPole




(b) Pendulum




(c) HalfCheetah

- Principal Component Analysis(PCA)는 가장 널리 사용되는 차원 축소 기법
- 기존 데이터의 분포를 최대한 보존하면서 고차원 공간의 데이터를 저차원 공간으로 변환
- 사람이 이해하기 어려운 3차원 이상 데이터의 분포를 간접적으로 확인할 수 있음


☑ 주성분 분석 예시



사람이 이해하기 어려운
6차원 데이터 시각화




PCA를 통해 2차원 데이터로 차원
축소 후 시각화




PCA를 통해 3차원 데이터로 차원
축소 후 시각화

④ 주성분 분석의 원리




- 기존 데이터가 공간에 퍼져있는 정도를 축소된 차원 공간에서 최대한 분리해서 유지하는 것이 목표
- 축소된 공간에서 데이터들의 분산 값을 추정함
- 추정된 분산을 최대화하는 축들의 조합을 찾는 것
- 수학적 정의: 입력 데이터들의 공분산 행렬에 대한 고유값 분해(Eigen Decomposition)

④ 주성분 분석 시각화



저차원 공간에서 비교적 잘 구분되는 데이터:
분류 문제의 난이도가 비교적 쉬울 것으로 예상




저차원 공간에서 구분이 잘 되지 않는 데이터:
(1) 3차원으로 차원 축소 시도 필요
(2) 분류 문제의 난이도가 어려울 것으로 예상

02

K-최근접 이웃(KNN)


머신러닝 분류 모델



용어


KNN: K-Nearest Neighbor
XGBoost: Extreme Gradient Boosting

☑ K-최근접 이웃(KNN)




- 예측하고자 하는 데이터 포인트를 거리 기반으로 분류
- 학습 데이터 중 가장 가까운 샘플들과 **거리**를 측정하여 분류를 수행함
- 모델을 학습하지 않고 거리의 값을 참조하기만 해서 게으른 학습 (Lazy Learning)이라고 부르기도 함
- 데이터의 특징과 클래스 간의 관계를 모델링하지 않음

④ 유클리디안(Euclidean) 거리




- 두 점 사이의 거리를 계산할 때 가장 흔히 쓰이는 방법
- 피타고라스 정리에서 사용되는 삼각형 빗변 길이 구하기와 동일함
- 유클리드 공간 내에서 N차원으로 일반화 가능

☑ KNN의 원리




- 초록색 데이터 포인트 분류
- $K=3$ 일 때, 최근접 이웃 중 빨간색이 가장 많으므로 빨간색으로 분류
- $K=5$ 일 때, 최근접 이웃 중 파란색이 가장 많으므로 파란색으로 분류
- K 파라미터의 크기에 따라 분류 성능이 크게 좌우됨

☑ KNN 분류 지도



K=1 일 때 KNN 분류 지도
이상치에 민감하게 분류




K=5 일 때 KNN 분류 지도
이상치에 대해 강건하게 분류

03


결정 트리

☑ 결정 트리(Decision Tree)




- 지도 학습 알고리즘의 한 종류
- 분류 및 회귀 문제에 사용 가능
- 각 노드(Node)는 관측값과 목표값을 연결시켜주는 예측 모델의 최소 단위
- 이해하기 쉽고 해석력이 좋은 것이 특징
- 모든 데이터에서 과적합되는 경향이 있음

④ 불순도(Impurity)와 엔트로피(Entropy)



Low Entropy




High Entropy

- 불순도: 한 범주 안에 서로 다른 데이터가 얼마나 섞여있는지 나타냄
- 엔트로피: 불순도를 수치적으로 나타낼 수 있는 가장 대표적인 불순도 함수



$$E = - \sum_{i=1}^k p_i \log_2(p_i)$$

☑ 결정 트리의 원리



- 정보 이득(Information Gain): 분기 이전의 불순도와 분기 이후의 불순도 차이
- 정보 이득을 최대로 하는 새로운 노드를 추가하는 방식으로 학습 진행
- 모든 데이터를 분류할 수 있을 때까지 노드 추가

④ 결정 트리 시각화




- 각 노드 분기가 하나의 이진 분류 모델 역할을 수행함
- 노드가 증가함에 따라 분류 표현력이 증가되는 것으로 이해할 수 있음

04

랜덤 포레스트

결정 트리의 문제점




- 결정 트리 모델에서 노드가 증가할수록 과적합(Overfitting)될 가능성이 커짐
- 모든 데이터를 분류할 수 있도록 상세한 노드를 계속해서 추가하기 때문
- 가지치기(Pruning) 등 과적합을 해결하기 위한 방법들이 연구되었지만 복잡한 데이터를 다루지 못함

☑ 앙상블(Ensemble) 모델




- 앙상블(Ensemble) 모델은 여러개의 모델을 조합하여 과적합을 방지하고 예측 성능을 높이는 방법
- 최종 결과는 투표(Voting), 평균 등 방법으로 통합

④ 랜덤 포레스트(Random Forest)




- 의사 결정 트리 모델에 앙상블을 적용한 것
- 각 결정 트리에는 **랜덤성**을 부과하여 서로 다른 표현을 학습하도록 유도
- 앙상블 모델의 학습 데이터는 중복을 허용한 상태로 전체 데이터에서 랜덤하게 추출하여 구성함
- 이러한 과정을 배깅(Bagging)이라고 함

☑ 랜덤 포레스트 시각화



- 배깅을 이용한 T개의 결정 트리로 구성된 랜덤 포레스트
- 최종 결과는 평균 또는 과반수 투표 방식으로 통합
- 여러 트리들의 평균은 노이즈에 대해 강건해짐
- 학습 시간이 길고 메모리 사용량이 큰 것이 단점

④ 랜덤 포레스트 사용 예시




- Microsoft의 키넥트 카메라 센서에 사용되어 더욱 유명해짐
- 관절 정보를 입력받아 사람의 자세를 인식하는 역할을 수행함

05


XGBoost

☑ 부스팅(Boosting)




- 배깅과 마찬가지로 복원 추출을 통해 각 앙상블 모델의 학습 데이터를 구성함
- 새로운 앙상블 모델을 추가할 때 직전 모델이 잘못 예측한 데이터에 가중치를 증가시킨 후 추출함
- 새로운 모델이 추가될 때 마다 오류 최소화를 목표로 학습됨
- 오류를 정의한다는 점에서 배깅 방법과 차별화 됨

☑ 경사 강하법(Gradient Descent)



- 볼록 함수에서 국소 최솟값의 미분값은 0임
- 미분을 통해 함수의 기울기를 구하고 기울기의 절대값이 낮은 쪽으로 모델을 조정하는 것을 경사 강하법이라고 함
- 극소값에 도달할 때까지 최적화를 반복함


☑ 그레이디언트 부스팅(Gradient Boosting)



- 기존 트리를 변경하지 않음
- 직전에 추가된 트리의 오류를 계산하고, 경사 하강법으로 오류를 최소화할 수 있는 새로운 트리를 추가함
- 결정 트리들의 선형 조합으로 최종 결과를 통합함
- 테스트 데이터 성능이 더 이상 개선되지 않을 때까지 학습 진행


✓ XGBoost (Extreme Gradient Boosting)

dmlc
XGBoost



- Gradient Boosting 알고리즘에 병렬 학습이 지원되도록 구현한 프로그램 라이브러리
- 과적합을 방지하기 위한 정규화(Regularization)가 포함됨
- 분류, 회귀 문제를 모두 지원하며, 구현체의 성능과 계산 효율이 좋음
- 머신러닝 알고리즘 중 성능이 가장 뛰어나다고 알려져있음

✓ XGBoost 대회 성적



- Kaggle은 전 세계 데이터 사이언티스트들이 참여할 수 있는 대회를 개최하는 최대 규모 커뮤니티 및 플랫폼
- Kaggle의 희스 보손 머신러닝 챌린지에서 XGBoost가 우월한 성능을 보이면서 유명해짐
- 현재까지 다른 모델과 비교했을 때 XGBoost가 압도적으로 많이 우승함

머신러닝 분류 모델

K-최근접 이웃 (KNN)	- 가장 가까운 K개의 이웃의 정보를 기반으로 분류 - 모델 학습 시간이 없는 게으른 학습 방법 - 고차원 데이터에서는 잘 작동하지 않음
결정 트리 (Decision Tree)	- 데이터를 분할하여 규칙을 생성하는 방식 - 시각화가 용이하고 해석이 쉬움 - 과적합이 쉽게 일어남
랜덤 포레스트 (Random Forest)	- 결정 트리의 종류 중 하나로, 배깅 기법을 사용함 - 단일 결정 트리의 단점인 과적합 문제를 완화함 - 학습 시간이 길고 해석하기 어려움
XGBoost	- 결정 트리의 종류 중 하나로, 경사 강하법과 부스팅 기법을 사용함 - 순차적으로 하나씩 트리를 추가하기 때문에 학습 시간이 빠름 - 설정할 파라미터가 많아서 정밀한 튜닝이 필요함

06

분류 모델 성능 평가 지표

회귀 모델 성능 평가 지표

MSE (Mean Squared Error)	오차를 제곱하기 때문에 큰 오차에 대해 큰 가중치를 부과하고, 이상치에 민감한 것이 특징
MAE (Mean Absolute Error)	- 모든 오차가 동일한 가중치를 가지기 때문에 이상치에 둔감한 것이 특징 - 종속 변수의 단위를 갖는 지표
RMSE (Root Mean Squared Error)	- MAE와 유사하게 종속변수의 단위를 가지는 평가 지표 - 제곱근의 영향으로 MSE보다 이상치에 덜 민감함 - MAE와 비교했을 때 큰 오차에 더 큰 가중치를 줌
R^2 (R Square)	- 모델이 데이터의 변동성을 얼마나 설명하고 있는지를 측정하는 지표 1에 가까울수록 데이터의 변동성을 완벽하게 설명하고 있음을 의미함

④ 성능 평가 지표(Evaluation Metrics)



- 머신 러닝 모델이 얼마나 데이터를 잘 예측하는지 측정하는 지표
- 테스트 데이터에 대해서 측정한 평가 지표를 개선하는 것이 중요함
- 회귀 모델은 연속된 숫자를 예측하기 때문에 오차가 큰 의미를 가짐
- 분류 모델에서는 정답률만으로 성능을 충분히 설명할 수 없어 추가적인 지표가 도입됨


오차 행렬(Confusion Matrix)



Confusion Matrix: 분류 모델의 예측에 어떤 유형의 오류가 있었는지 확인하기 위한 지표

		예측 클래스 (Predictied Class)	
		Negative	Positive
실제 클래스 (Actual Class)	Negative	TN (True Negative)	FP (False Positive)
	Positive	FN (False Negative)	TP (True Positive)

정밀도(Precision)와 재현율(Recall)



- 정답률은 모든 데이터에 대해 정답을 맞춘 비율

$$\text{Accuracy} = \frac{TP + TN}{Total}$$

- 정밀도는 Positive라고 예측한 것 중 실제 Positive의 비율

$$\text{Precision} = \frac{TP}{TP + FP}$$

- 재현율은 실제 Positive인 것 중 올바르게 Positive라고 예측한 것의 비율

$$\text{Recall} = \frac{TP}{TP + FN}$$

✔ 정밀도와 재현율 예시



정밀도가 중요한 경우:


스팸 차단 모델에서는 적게 예측하더라도 스팸 내용만 검출해야하기 때문에 정밀도가 높아야 함



재현율이 중요한 경우:

암 예측 모델에서는 실제 암을 판독하지 못하는 경우가 발생하면 안되기 때문에 재현율이 높아야 함

④ F1 점수




- F1 점수는 정밀도와 재현율을 결합한 지표
- 정밀도와 재현율의 **조화 평균**

$$F1 = 2 \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

- 임계값 조정으로 인한 성능 조작을 방지함

☑ AUC-ROC 점수



- ROC(Receiver Operation Characteristic) 곡선은 TPR과 FPR의 트레이드 오프를 표현한 그래프
- ROC 곡선 아래의 면적을 AUC-ROC 점수라고 함
- 랜덤으로 분류하면 0.5에 가까워짐
- 완벽하게 분류할수록 1에 가까워짐



용어

TPR: True Positive 비율(재현율과 동일함)

FPR: False Positive 비율

AUC: Area Under Curve

④ 분류 모델 성능 평가 지표

정답률 (Accuracy)	모든 데이터에 대해 정답을 맞춘 비율 $\text{Accuracy} = \frac{TP + TN}{Total}$
정밀도 (Precision)	Positive라고 예측한 것 중 실제 Positive의 비율 $\text{Precision} = \frac{TP}{TP + FP}$
재현률 (Recall)	실제 Positive인 것 중 올바르게 Positive라고 예측한 것의 비율 $\text{Recall} = \frac{TP}{TP + FN}$
F1 점수	- 정밀도와 재현률의 조화 평균 - 임계값 조정으로 인한 성능 조작을 방지함
AUC-ROC 점수	- TPR/FPR 트레이드 오프 곡선 아래의 면적 - 랜덤한 모델의 성능은 0.5, 완벽한 모델의 성능은 1.0에 가까움