

인공지능을 활용한 양극소재 기반 배터리 특성 예측

06 양극재 결정구조 분류 정확도 향상을 위한 AI 방법론

목차

—
양극재 결정구조 분류
정확도 향상을 위한 AI
방법론

- 01 **인공신경망의 학습과 추론**
- 02 **학습 조기 종료(Early Stopping)**
- 03 **데이터 증강**
- 04 **가중치 규제**
- 05 **드롭아웃**
- 06 **AutoML**
- 07 **기타 딥러닝 심화 기법들**

01


인공신경망의 학습과 추론

④ 인공지능의 학습 목표 – 일반화를 기반으로 한 지능적 추론



- 인공지능 모델을 구현하고 학습하는 이유는 데이터셋에 대한 일반적인 패턴을 찾고 이를 이용한 추론을 하기 위함
- 일반적인 패턴을 찾는 과정을 학습이라고 함
- 모델을 사용해 최종 이득을 보는 과정을 추론이라고 함

④ 인공지능망 학습 과정



④ 인공지능 모델의 학습과 추론 과정

학습

- 학습 데이터를 이용해 일반적인 패턴을 찾는 과정
- 검증 데이터를 이용해 과적합을 방지하기도 함
- 학습 데이터의 비율이 가장 크고 많은 반복이 필요함
- 기울기 계산에 매우 긴 연산 시간이 듦


테스트

- 학습된 모델이 일반적 추론 능력을 갖고 있는지 테스트 하는 단계
- 테스트 결과를 참고해 학습을 다시 진행할지 결정
- 테스트 데이터의 크기 만큼 추론해야 함

추론

- 학습된 모델을 실질적으로 사용하는 단계
- 기울기를 추적하지 않아도 되기 때문에 연산이 매우 빠름
- 실시간으로 작동하는 모델의 경우 배치의 크기가 1임


④ 인공지능경망 추론 과정



인공지능망 학습과 추론 비교

	배치 데이터 구성	데이터 전처리	신경망 순전파	손실량 계산	역전파 기울기 계산	옵티마이저 최적화	테스트 데이터 검증
학습	전체 학습 데이터 중 N개 데이터 샘플링	데이터셋 구성할 때 완료	N개 데이터 순전파	N개의 정답 데이터와 비교하여 손실량 계산	기울기 계산에 매우 큰 연산량 필요	신경망 파라미터 최적화	과적합 여부 판단
추론	1개 데이터	학습 데이터셋과 동일하게 전처리 필요	1개 데이터 순전파	N/A	N/A	N/A	N/A

④ 그래픽카드의 사용




- 그래픽카드(Graphics Processing Unit)가 인공지능에 활용되면서 인공지능 기술 개발이 가속화됨
- 병렬 계산에 최적화되어 **N개의 배치 데이터를 동시에** 처리할 수 있음
- 학습 속도를 획기적으로 단축시키고, 실시간 추론이 필요한 분야에 큰 도움을 줌
- 합성곱 신경망 등 모델의 크기가 클수록 CPU보다 연산 효율이 좋음
- CPU-GPU 병목 현상 때문에 속도가 무조건 빨라지는 것은 아님

02


학습 조기 종료(Early Stopping)

④ 학습 데이터 과적합




- 학습 데이터에 대해 반복적인 최적화를 거듭하기 때문에 과적합(overfitting)을 피할 수 없음
- 과적합된 모델은 새로운 데이터에 대해 일반적인 예측을 할 수 없음

✓ 학습/검증 손실량 그래프



- 모델 학습 과정을 확인할 수 있는 가장 대표적인 그래프
- 학습 손실은 학습 데이터셋에 대해 순전파를 거친 후 측정됨
- 학습 데이터를 잘 학습함에 따라 손실이 지속적으로 낮아지고 결국 과적합됨
- 검증 손실은 학습이 이뤄진 후 검증 데이터셋에 대해 순전파를 거친 후 측정됨
- 과적합을 조기에 발견할 수 있는 지표가 됨

④ 조기 종료(Early Stopping)



- 지정한 에폭만큼 학습 & 검증을 반복함
- 과적합이 발견되면 학습을 조기에 종료하는 것이 효율적임
- 검증 손실(Validation Loss)를 판단 지표로 사용하는 경우가 많음
- 지역 극소점을 극복하여 손실이 더 감소할 수도 있기 때문에 여유 에폭을 두고 종료함 (Patience)
- 검증 손실이 최소였을 때의 모델 파라미터를 저장함

03

데이터 증강

④ 데이터셋 크기의 중요성

챗GPT로 확 커지는 생성형 AI 시장... 양질 데이터 중요도


글로벌 리서치 기관 그랜드 뷰 리서치가 2023년 4월 발간한 리포트에 따르면 ChatGPT 등 생성형 AI에서 비롯된 데이터 서비스 및 솔루션 수요는 2022년 글로벌 인공지능 데이터 시장에서 약 0.9조를 차지했다. 또 2030년에는 약 6.6조를 차지할 것으로 전망됐다. 국내 시장에서도 생성형 AI로 인한 데이터 수요는 2022년 493억원에서 2030년 4천261억원으로 연평균 31.8%로 성장할 것으로 예상된다.

(중략)

특히, 정부는 기술과 산업 인프라 확충을 위해 분야별 특화 학습용 데이터와 비영어권 언어 데이터를 2027년까지 200종(책 15만권 분량)을 구축할 계획을 강조했다. 이를 통해 초거대 AI 개발 및 고도화를 지원한다는 계획이다. 아울러 초거대 AI 서비스에서 발생 가능한 위험 요인과 성능에 대한 평가를 제3기관을 통해 지원한다고도 밝혔다. 이를 위해 비윤리적이거나 유해한 표현 및 사실 왜곡 등을 검증할 수 있는 데이터셋 구축을 추진할 예정이다.




❑ 불충분한 데이터셋




- 인공지능은 큰 규모의 데이터셋을 필요로 함
- 학습 데이터가 현실의 상황을 모두 표현할 수 있어야 함
- 현실적인 문제로 데이터셋의 크기가 불충분할 수 있음
- 데이터를 획득하는 것 자체가 어려운 경우
- 데이터 라벨링에 투입할 자원이 부족한 경우

④ 불균형한 데이터셋



- 현실적인 이유로 라벨 당 데이터 크기 사이에 불균형이 존재할 수 있음
- 인공지능 모델 특성상 적은 데이터 예측을 포기하고 다수의 데이터만 잘 맞추려는 경향을 보임 (실제 전체 성능은 향상됨)
- 클래스 별 데이터 획득 시 소모되는 자원의 차이 때문에 발생할 수 있음


☑ 데이터 증강(Data Augmentation)



Enlarge your Dataset



- 데이터가 부족할 때 기존 데이터에 변형을 가해 데이터 양을 증가시키는 방법
- 데이터의 다양성을 증가시키며 과적합을 방지함 (robustness)
- 실세계의 다양한 조건을 모의할 수 있고 모델의 일반화 성능을 높임
- 데이터 증강을 과도하게 적용하면 비현실적인 데이터가 생성될 수도 있음
- 일반적으로 데이터 로더(Loader)나 모델의 입력층에 적용함

④ 이미지 데이터 증강



- 학습 데이터에 대해 반복적인 최적화를 거듭하기 때문에 과적합(overfitting)을 피할 수 없음
- 과적합된 모델은 새로운 데이터에 대해 일반적인 예측을 할 수 없음

④ 연속형 데이터 증강




- 학습 데이터에 대해 반복적인 최적화를 거듭하기 때문에 과적합(overfitting)을 피할 수 없음
- 과적합된 모델은 새로운 데이터에 대해 일반적인 예측을 할 수 없음


04

가중치 규제


④ 편향-분산 트레이드오프(Bias-Variance Tradeoff)




치우침 낮음, 분산 낮음



높은 편향, 분산 낮음:







낮은 편향, 분산 높음:



높은 편향, 분산 높음:


- 지도 학습에서 가장 중요한 문제 중 하나로 기대 오차를 분석하는 방법임
- 오차의 편향과 분산을 동시에 분석할 때 모두 최소화해야 한다는 관점
- 과적합된 모델은 편향이 적고 분산이 높다고 해석할 수 있음

☑ 모델 규제




- 머신러닝 모델의 학습 과정에 규제를 가하는 방법
- 일반적으로 규제를 통해 에러의 편향에서 손해를 보더라도 에러의 분산을 줄이고자 함
- 과적합을 방지하는 대표적인 방법 중 하나

가중치 규제(Weight Regularization)



- 모델의 가중치의 크기에 규제를 가하는 방법
- 모든 가중치를 포함하는 행렬을 W 라고 할 때:
$$E_{reg}(W) = E(W) + \lambda W^T W$$
- 손실 함수에 가중치 규제 항을 추가하여 학습을 진행함
- 가중치의 제곱합을 추가하여 가중치가 과도하게 커지지 않도록 유도함 (L2 Regularization)
- λ 를 조절함으로써 규제 정도를 조정함

☑ 가중치 규제 예시




- λ 값이 너무 작으면 과적합(Overfitting)됨
- 반대로 λ 값이 너무 크면 학습 과정을 과도하게 방해하여 과소적합(Underfitting)됨
- 적절한 규제값을 설정하는 것이 중요함


05

드롭아웃

④ 드롭아웃(Dropout)




(a) Standard Neural Net



(b) After applying dropout.


- 확률적으로 뉴런을 비활성화시켜 값이 순전파되지 않도록 하는 방법
- 인공신경망 규제 방법 중 하나로, 신경망이 깊을 때 과적합을 방지하는 대표적인 방법
- 학습이 완료된 후에는 드롭아웃을 비활성화하여 예측 성능을 높임

☑ 드롭아웃의 원리




- 인공신경망 모델의 다음 은닉층에 강제로 부족한 정보를 이용해 추론하도록 함
- 부분적인 정보를 이용해 예측하도록 훈련되어 학습데이터에 과적합되는 문제를 방지함

④ 드롭아웃 예시



(a) Without dropout

(b) Dropout with $p = 0.5$.


- MNIST 데이터셋에서 인공신경망이 학습한 이미지 표현
- 드롭아웃이 적용된 모델이 더 일반적인 피쳐 표현을 학습함

06


AutoML

☑ 모델 설정에 따른 성능 차이

Game	DQN	DDQN	Prior. DDQN	Duel. DDQN	Distrib. DQN	Noisy DQN	Rainbow
alien	1620.0	3747.7	6,648.6	4,461.4	4,055.8	2,394.9	9,491.7
amidar	978.0	1793.3	2,051.8	2,354.5	1,267.9	1,608.0	5,131.2
assault	4280.0	5393.2	7,965.7	4,621.0	5,909.0	5,198.6	14,198.5
asterix	4359.0	17356.5	41,268.0	28,188.0	400,529.5	12,403.8	428,200.3
asteroids	1364.5	734.7	1,699.3	2,837.7	2,354.7	4,814.1	2,712.8
atlantis	279987.0	106056.0	427,658.0	382,572.0	273,895.0	329,010.0	826,659.5
bank_heist	455.0	1030.6	1,126.8	1,611.9	1,056.7	1,323.0	1,358.0
battle_zone	29900.0	31700.0	38,130.0	37,150.0	41,145.0	32,050.0	62,010.0
beam_rider	8627.5	13772.8	22,430.7	12,164.0	13,213.4	12,534.0	16,850.2
berzerk	585.6	1225.4	1,614.2	1,472.6	1,421.8	837.3	2,545.6
bowling	50.4	68.1	62.6	65.5	74.1	77.3	30.0
boxing	88.0	91.6	98.8	99.4	98.1	83.3	99.6
breakout	385.5	418.5	381.5	345.3	612.5	459.1	417.5
centipede	4657.7	5409.4	5,175.4	7,561.4	9,015.5	4,355.8	8,167.3
chopper_command	6126.0	5809.0	5,135.0	11,215.0	13,136.0	9,519.0	16,654.0
crazy_climber	110763.0	117282.0	183,137.0	143,570.0	178,355.0	118,768.0	168,788.5
defender	23633.0	35338.5	24,162.5	42,214.0	37,896.8	23,083.0	55,105.0
demon_attack	12149.4	58044.2	70,171.8	60,813.3	110,626.5	24,950.1	111,185.2
double_dunk	-6.6	-5.5	4.8	0.1	-3.8	-1.8	-0.3
enduro	729.0	1211.8	2,155.0	2,258.2	2,259.3	1,129.2	2,125.9
fishing_derby	-4.9	15.5	30.2	46.4	9.1	7.7	31.3
freeway	30.8	33.3	32.9	0.0	33.6	32.0	34.0
frostbite	797.4	1683.3	3,421.6	4,672.8	3,938.2	583.6	9,590.5
gopher	8777.4	14840.8	49,097.4	15,718.4	28,841.0	15,107.9	70,354.6
gravitar	473.0	412.0	330.5	588.0	681.0	443.5	1,419.3
hero	20437.8	20130.2	27,153.9	20,818.2	33,860.9	5,053.1	55,887.4
ice_hockey	-1.9	-2.7	0.3	0.5	1.3	-2.1	1.1
kangaroo	7259.0	12992.0	14,492.0	14,854.0	12,909.0	12,117.0	14,637.5
krull	8422.3	7920.5	10,263.1	11,451.9	9,885.9	9,061.9	8,741.5
kung_fu_master	26059.0	29710.0	43,470.0	34,294.0	43,009.0	34,099.0	52,181.0
montezuma_revenge	0.0	0.0	0.0	0.0	367.0	0.0	384.0
ms_pacman	3085.6	2711.4	4,751.2	6,283.5	3,769.2	2,501.6	5,380.4
name_this_game	8207.8	10616.0	13,439.4	11,971.1	12,983.6	8,332.4	13,136.0
phoenix	8485.2	12252.5	32,808.3	23,092.2	34,775.0	16,974.3	108,528.6
pitfall	-286.1	-29.9	0.0	0.0	-2.1	-18.2	0.0
pong	19.5	20.9	20.7	21.0	20.8	21.0	20.9
private_eye	146.7	129.7	200.0	103.0	15,172.9	3,966.0	4,234.0
qbert	13117.3	15088.5	18,802.8	19,220.3	16,956.0	15,276.3	33,817.5
road_runner	39544.0	44127.0	62,785.0	69,524.0	63,366.0	41,681.0	62,041.0
robotank	63.9	65.1	58.6	65.3	54.2	53.5	61.4
sequest	5860.6	16452.7	44,417.4	50,254.2	4,754.4	2,495.4	15,898.9
skiing	-13062.3	-9021.8	-9,900.5	-8,857.4	-14,959.8	-16,307.3	-12,957.8
solaris	3482.8	3067.8	1,710.8	2,250.8	5,643.1	3,204.5	3,560.3
space_invaders	1692.3	2525.5	7,696.9	6,427.3	6,869.1	2,145.5	18,789.0
star_gunner	54282.0	60142.0	56,641.0	89,238.0	69,306.5	34,504.5	127,029.0
surround	-5.6	-2.9	2.1	4.4	6.2	-3.3	9.7
tennis	12.2	-22.8	0.0	5.1	23.6	0.0	-0.0
time_pilot	4870.0	8339.0	11,448.0	11,666.0	7,875.0	6,157.0	12,926.0
tutankham	68.1	218.4	87.2	211.4	249.4	231.6	241.0
venture	163.0	98.0	863.0	497.0	1,107.0	0.0	5.5
video_pinball	196760.4	309941.9	406,420.4	98,209.5	478,646.7	270,444.6	533,936.5
wizard_of_wor	2704.0	7492.0	10,373.0	7,855.0	15,994.5	5,432.0	17,862.5
yars_revenge	18089.9	11712.6	16,451.7	49,622.1	16,608.6	9,570.1	102,557.0
zaxxon	5363.0	10163.0	13,490.0	12,944.0	18,347.5	9,390.0	22,209.5




④ Automated Machine Learning (AutoML)



- 자동화된 머신러닝(AutoML)은 데이터에 맞는 가장 적합한 모델을 자동으로 선택함
- 모델의 성능을 최적화하기 위해 다양한 파라미터를 조합하며 하이퍼파라미터 튜닝을 진행함
- 단기간에 성능을 향상시키고 시간을 절약할 수 있음
- 도메인 지식이 필요한 경우 성능이 떨어질 수 있음
- 최신 AutoML 서비스들은 학습된 모델을 선정하고 배포까지 자동화되어 있음

WandB




- 학습 결과를 실시간으로 시각화해주는 온라인 서비스
- 다양한 하이퍼파라미터튜닝 방법을 제공해 AutoML을 손쉽게 적용할 수 있음
- 파라미터 별 성능과의 상관 관계를 분석해줌
- 그리드 탐색, 베이지안 최적화 등 AutoML 기법 구현
- 무료로 사용 가능

07

기타 딥러닝 심화 기법들

☑ Residual Connections (ResNet)


$$\mathbf{y} = \mathbf{x} + \mathcal{F}(\mathbf{x})$$




- 신경망 학습의 기울기 소실 문제를 해결할 수 있는 대표적인 방법 중 하나
- 각 레이어의 출력에 입력을 직접 더하는 Skip Connection 구조를 사용함
- 매우 깊은 딥러닝 모델을 구성할 때 필수적인 요소
- Residual Connection들로 이뤄진 ResNet은 현대 대부분의 큰 딥러닝 모델에 구성 요소로 활용되고 있음

④ 순환신경망(RNN)


one to one




one to many




many to one



many to many




many to many




- 시계열 데이터, 문자열 데이터를 처리하는데 적합한 신경망
- 과거의 정보를 활용해 다음 예측을 수행하기 때문에 순환신경망이라고 부름
- 정보가 순환되는 RNN 유닛은 동일한 파라미터를 공유함

④ 합성곱 신경망(CNN)




- 임의 크기의 커널을 모든 이미지에 대해 합성곱(Convolution)을 수행하는 레이어를 합성곱 레이어라고 함
- 합성곱 커널은 동일한 파라미터를 공유하기 때문에 적은 파라미터로 핵심적인 특징점을 추출할 수 있다는 점에서 이미지 데이터에 적합한 네트워크

④ LeNet



- 손글씨 데이터를 분류하기 위한 초기의 CNN 모델 (1998)
- 합성곱 레이어를 반복하다가 평탄화(Flatten)한 후, MLP 레이어를 이용해 출력층의 크기까지 인코딩함
- 이후 AlexNet 등 중요한 CNN 모델들의 기초가 됨

④ 트랜스포머(Transformer)



- 자연어 처리 분야에서 초기에 연구된 트랜스포머 구조
- 최근 이미지, 동영상, 포인트클라우드 등 다양한 분야에 접목되면서 강력한 특징 분석 성능을 보임
- ChatGPT, Stable Diffusion 등 최신 인공지능 기술에 모두 적용되는 핵심 네트워크